

## Contents

|                                                                                    |   |
|------------------------------------------------------------------------------------|---|
| 3. Generative Agents y el marco CRSEC: razonamiento social mediante LLMs . . . . . | 1 |
| 3.1 Los Generative Agents: memoria, reflexión y planificación . . . . .            | 1 |
| 3.2 El marco CRSEC: emergencia de normas sociales . . . . .                        | 1 |
| 3.3 Evidencia empírica: razonar, evaluar conflictos y propagar . . . . .           | 1 |
| 3.4 Limitaciones y costos: el puente hacia arquitecturas híbridas . . . . .        | 2 |
| Referencias nuevas . . . . .                                                       | 2 |

### 3. Generative Agents y el marco CRSEC: razonamiento social mediante LLMs

Los dos apartados previos analizaron arquitecturas cuyo comportamiento social está codificado por el diseñador (FSM/Utility AI) o gobernado por reglas afectivas y sociales predefinidas (CiF). Este apartado documenta el punto en que la literatura delega el razonamiento social de alto nivel a Modelos de Lenguaje Extensos (LLMs), tomando como fuentes fundacionales a Park et al. (2023) [8] y a Ren et al. (2024) [9].

#### 3.1 Los Generative Agents: memoria, reflexión y planificación

Park et al. [8] introducen los *Generative Agents*: agentes de software computacional que emplean un LLM para simular comportamiento humano creíble. La arquitectura extiende el modelo de lenguaje con tres componentes acoplados. Primero, un *memory stream* (flujo de memoria) que almacena en lenguaje natural un registro completo de las experiencias del agente; cada recuerdo se recupera dinámicamente ponderando tres factores: recencia, importancia y relevancia respecto a la situación actual. Segundo, un mecanismo de *reflection* (reflexión) que sintetiza periódicamente los recuerdos de bajo nivel en inferencias de mayor abstracción. Tercero, un módulo de *planning* que traduce esas reflexiones en planes diarios que el agente ejecuta y re-planifica ante cambios. Para anclar el razonamiento lingüístico al mundo, los autores representan el entorno (áreas y objetos) como una estructura de árbol que se traduce a lenguaje natural (p. ej., “hay una estufa en la cocina”), y cada agente mantiene un subárbol que actualiza al navegar. Este mecanismo de anclaje espacial es un artificio de traducción texto↔mundo, no una capacidad espacial nativa del LLM —observación relevante para su transferencia a entornos 3D.

#### 3.2 El marco CRSEC: emergencia de normas sociales

Ren et al. [9] parten de una limitación observada: aunque los LLMs embeben normas sociales de su corpus, los sistemas multiagente generativos (*generative MASs*) “carecen de la capacidad de ser normativos”. Proponen CRSEC, que según los autores es la primera arquitectura normativa para generative MASs, compuesta por cuatro módulos. **Creation & Representation** (Creación y Representación): agentes “emprendedores de normas” (*norm entrepreneurs*) generan normas personales, representadas formalmente mediante un quintuple  $\langle c, u, \alpha, s\_act, s\_val \rangle$  donde  $c$  es la norma en lenguaje natural,  $u$  su utilidad (escala 1–100),  $\alpha$  su tipo (descriptiva o injuntiva) y  $s\_act/s\_val$  variables booleanas de activación y validez. **Spreading** (Propagación): las normas se difunden por comunicación (un emisor detecta conflictos mediante `DetectConflict` y decide conversar; un receptor identifica información normativa de los diálogos) y por observación del comportamiento ajeno. **Evaluation** (Evaluación): un *sanity check* inmediato verifica consistencia, duplicación, tipo y ausencia de conflicto, y una síntesis a largo plazo mantiene las normas compactas y concisas. **Compliance** (Cumplimiento): eleva la conciencia del agente sobre sus normas al generar planes (`GenerateNormativePlans`) y acciones (`GenerateNormativeActions`), otorgándole autonomía para cumplirlas o no. En conjunto, los módulos operacionalizan las cinco preguntas del proceso emergente: de dónde vienen las normas, cómo se representan, cómo se propagan, cómo se examinan y sintetizan, y cómo se incorporan a la planificación y la acción.

#### 3.3 Evidencia empírica: razonar, evaluar conflictos y propagar

Ambos trabajos se validan en el entorno sandbox Smallville. Park et al. [8] poblaron el pueblo con 25 agentes durante dos días de juego y midieron tres fenómenos emergentes no programados: difusión de información, formación de relaciones y coordinación. Partiendo de una única intención sembrada (Isabella quiere organizar una fiesta de San Valentín), los agentes propagaron autónomamente las invitaciones: la proporción de agentes que conocían la fiesta creció de 4% a 48%, y la de la candidatura de Sam a alcalde de 4% a 32%; la densidad de la red social pasó de 0.167

a 0.74, y solo el 1.3% de las respuestas de los agentes sobre su conocimiento de otros fueron alucinadas. Ren et al. [9] configuraron 10 agentes (3 emprendedores y 7 ordinarios) con valores en conflicto (fumar, hablar alto, dar propina) y demostraron —en sus propias palabras— que “las normas sociales siempre emergen en múltiples corridas independientes, llevando al 100% de los agentes a aceptar ciertos estándares de comportamiento como sus normas personales y a cumplirlos en sus planes y acciones; además, a medida que las normas sociales emergen, los conflictos sociales casi desaparecen”. Reportan asimismo que las conversaciones y los pensamientos impulsan la emergencia; que las normas descriptivas son más difíciles de establecer que las injuntivas (la norma descriptiva “dar propina” tardó hasta el final del Día 2, frente a las injuntivas ya emergidas en el Día 1), aunque los emprendedores de normas pueden moldear su emergencia; y una evaluación humana con 30 evaluadores arrojó una puntuación media de  $5.63 \pm 0.03$  en escala Likert de 7 puntos. Juntos, estos experimentos evidencian empíricamente que un LLM permite a los agentes razonar sobre normas, detectar conflictos entre valores y propagar información/normas en un sistema multiagente.

### 3.4 Limitaciones y costos: el puente hacia arquitecturas híbridas

Estos resultados conllevan costos que motivan arquitecturas más eficientes. Park et al. [8] reportan que simular 25 agentes por dos días requirió tiempo y recursos sustanciales, con “el estudio completo incurriendo en costos de miles de dólares”; caracterizaciones posteriores cuantifican esa carga en aproximadamente  $25.41M \pm 0.96M$  de tokens por corrida del pueblo de 25 agentes (Yu et al., “Affordable Generative Agents”, arXiv:2402.02053, Tabla 1) [10]. Los propios autores proponen como trabajo futuro paralelizar los agentes o desarrollar modelos de lenguaje diseñados específicamente para agentes generativos, y señalan que sus errores más comunes surgieron cuando el agente no recuperaba memorias relevantes o fabricaba embellecimientos. Ren et al. [9] reportan textualmente que utilizaron GPT-3.5 y GPT-4, se enfocaron en el escenario “Hobbs Café” y que “cada corrida cuesta más de 500 dólares y cerca de 7 días en completarse”, además de observar errores de los LLMs al clasificar tipos de norma o al asignar utilidades (mayormente 80–100, sin distinguir importancias sutiles). [Sin confirmar] Cabe aclarar que Ren et al. no incluyen una sección formal de “Limitaciones/Conclusión” —su sección final se titula “Discussions”— y no enuncian explícitamente la escalabilidad a más agentes, el anclaje espacial ni la coherencia a largo plazo como limitaciones propias; estos factores se infieren aquí del diseño experimental (10 agentes, un solo escenario, 2 días) y no deben atribuirse literalmente a los autores.

A ello se suma un cuello de botella crítico para entornos 3D en tiempo real: la latencia. En el benchmark GVGAI-LLM (Zhang et al., arXiv:2508.08501, Apéndice D), “los agentes basados en LLM son de dos a tres órdenes de magnitud más lentos que los métodos de búsqueda simbólica” —MCTS resuelve cada movimiento en 0.04 s frente a 2.37 s (GPT-4o-mini), 27.82 s (Gemini-2.5-pro) o 166.00 s (DeepSeek Reasoner) por movimiento— lo que los hace poco prácticos para bucles de control con presupuestos de milisegundos. Estas restricciones —costo de cómputo, latencia, anclaje espacial indirecto, coherencia a largo plazo y escalabilidad a muchos agentes— constituyen el argumento central para el enfoque híbrido que se desarrolla en el siguiente apartado: combinar la deliberación semántica de un LLM compacto con la ejecución táctica eficiente y verificable de un planificador simbólico como GOAP.

---

### Referencias nuevas

[8] Park, J. S., O’Brien, J., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative Agents: Interactive Simulacra of Human Behavior. En Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST ’23). Association for Computing Machinery. <https://doi.org/10.1145/3586183.3606763> (versión arXiv: arXiv:2304.03442). — *Adición nueva a la bibliografía del anteproyecto.*

[9] Ren, S., Cui, Z., Song, R., Wang, Z., & Hu, S. (2024). Emergence of Social Norms in Generative Agent Societies: Principles and Architecture. En Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI-24), pp. 7895–7903. <https://doi.org/10.24963/ijcai.2024/874> (versión arXiv: arXiv:2403.08251). — *Adición nueva a la bibliografía del anteproyecto (fuente primaria de CRSEC).*

[10] Yu, G., Zhang, Y., et al. (2024). Affordable Generative Agents. arXiv:2402.02053. — *Referencia complementaria usada solo para cuantificar el costo de cómputo de Park et al.*

---

*Nota para el usuario:* Se consultaron **en texto completo** el PDF de las actas IJCAI 2024 (0874.pdf) y la versión arXiv (2403.08251, HTML v1/v2 y PDF) de Ren et al., así como el PDF/HTML de arXiv (2304.03442) y el HTML de ACM Digital Library de Park et al.; **ambas fuentes primarias [8] y [9] se verificaron directamente** (autores, año, venue —UIST 2023 e IJCAI-24, Special Track on Human-Centred AI, pp. 7895–7903— y DOIs confirmados). La referencia complementaria [10] (Yu et al., “Affordable Generative Agents”, arXiv:2402.02053) y el benchmark de latencia GVGAI-LLM (arXiv:2508.08501) se citaron a partir de sus datos reportados pero **no se verificaron página por página en texto completo**; conviene confirmar los años/autores exactos y las cifras (25.41M tokens; 0.04 s vs. 2.37/27.82/166.00 s por movimiento) antes de integrarlos a la bibliografía final. Se recomienda además reenumerar [10] si el usuario decide no incluir la fuente complementaria.